ChampiQuest

Prévision de pousse de champignons et reconaissance visuelle

Objectif

- Pouvoir prédire quand un champignon va pousser
- A partir d’une image de champignon, reconnaître son espèce
- Permettre une utilisation simple de ces 2 modèles

• Prédire quand un champignon va pousser

- Données à notre disposition : Dataset indiquant des présences
- Data météo
- Data concernant la géologie, le type d’environnement (plain, forêt de résineux, etc)

Pas d’absence

- Le dataset principal est celui indiquant les présences de champignons, avec la date et une localisation *approximative*
- À l’aide de règle métier on essaye de produire des absences cohérentes (par exemple, des champignons ont été relevés mais pas notre target ou encore champi détécté à un jour J → on considère qu’à J-3 et J+3 il était déjà là)

Feature ing

- Des features indiquant la tendance météorologique passée ont été crées
- Pour palier au manque de data, des champi ayant une très forte colinéarités avec nortre target sont utilisés pendant le train comme faisant partie de notre target
- La localisation n’est pas utilisé dans le train (afin de pouvoir généraliser et ne pas apprendre par coeur les spots connus) et sert à connaître l’environnement de l’endroit

Évaluation ds modèles

- Différents modeles lightGBM avec divers paramètres ont été évalués pour déterminer les paramètres optimaux et ont été comparé à une régression logistique servant de baseline
- Cross-validation : Les modèles sont train sur un ensemble d’année puis doivent prédire pour l’année qui a été retiré du dataset de train, et cela plusieurs fois avec une année différente gardée hors du train

Interprétations des Shap values

- Les shaps Values de nos modèles (lightGBM) semblent indiquer que pas mal de features sont inutiles et les enlever ne change rien au modèles. Cela peut être lié aux coordonnées GPS qui sont trop peu précise pour en tirer réellement quelque chose.

Servir les prédictions

- Mise en place d’un endpoint API renvoyant les prédiction selon la date et le lieu
- Heatmap indiquant les probabilités de présences des targets

Reconnaissance visuelle

- Dataset d’images + label préexistant et de qualité
- Entrainement à partir d’un réseau de neuronne convolutif (ConvNext)

Sécurité des cueilleurs

- Toutes les erreurs du modèle ne se valent pas, ainsi une étape post training permet de calibrer les prédictions pour que le modèle soit plus frileux à indiquer un champignon comme comestible lorsqu’il y a un doute et à l’inverse préfère indiquer un champignon comme non comestible meme s’il y a un doute

- Les espèces ressemblant fortement à nos targets ont étés ciblés afin que dans nos data ils soient suffisament présent et le modèle assez bon pour les détecter
- On a également un dataset qui ne contient pas de champi pour apprendre au modele à dire je ne vois pas de champi ainsi qu’une catégorie autre champi pour les champis qui ne sont pas des target ou de faux amis

- Une petite interface a été créé pour pouvoir upload facielement une image et avoir un résultat facilement lisible sur la comestibilité du champi

Déploiment et mise en prod

- LightGBM et convnext sont de petits modèles qui ne demande pas beaucoup de puissance de calcul (comparé aux LLM)
- Tout est packagé dans une image docker, elle même créé après les test d’intégrations réussis. L’image est alors stockée via github, il suffit alors de la pull

Préidctions au jour le jour

- Tout les jours on peut faire les prédictions pour l’ensemble du territoire qui nous concerne (vosges + foret noire)
- On récupère les nouvelles prédictions météos et on update celle d’il y a 5 jour (on a accès a une données plus précise pour J-5)

Difficultés rencontrées

- La faible quantité ET qualité de data pour la présence ou non de champignons et leur géolocalisation
- Les limites d’API gratuite pour récupérer des données météo

Améliorations et Perspéctives

- Trouver toujours plus de données
- Si mis en prod, récupérer les données des utilisateurs (avec leur consentement) pour améliorer nos modèles